تمرین روز سوم بوت کمپ عامل‌های هوشمند

از API تا پاسخ مستند با PostgreSQL و LangGraph

هدف: یک سامانهٔ پژوهش فنی با کنترل مالکیت، API، ورود اسناد، embedding، بازیابی و ارزیابی بسازید. مبنا اسلایدهای جلسهٔ سوم است؛ کاربرد آموزشی روی PEP ۲۴ واقعی و داده‌های مصنوعی برچسب‌دار اجرا می‌شود.

تمرین شامل ۴۸ سؤال مفهومی با ۲۴ نمره و ۹۶ سؤال عملی با ۷۶ نمره. برای هر انتخاب مفهومی دلیل کوتاه و برای هر فعالیت عملی کد، خروجی و تحلیل ارائه کنید.

تحویل: نوت‌بوک قابل اجرای کامل، فرم HTML تکمیل‌شده و ZIP شامل migration و seed و گزارش‌های اجرا. هر زیرسؤال سه سلول داشته باشد: صورت سؤال و توضیح، کد انگلیسی، تحلیل فارسی راست‌به‌چپ. بذر مرجع 20261015 است.

داده‌ها در Day3_Datasets و مدل محلی در Day3_Resources هستند. مسیر داده جلوی هر بخش آمده است. PostgreSQL را با Docker یا DATABASE_URL طبق Day3_Grading/README.md آماده کنید؛ نام schema با DB_SCHEMA قابل تنظیم است.

انتخاب تنظیمات فقط با train/dev؛ test برای سنجش نهایی است. gold آزمون بازیابی و پاسخ‌پذیری در بستهٔ مدرس است؛ دانشجو فایل‌های prediction بخش ۹ را تحویل می‌دهد. مدل embedding انگلیسی است؛ تحلیل‌ها فارسی باشند.

برای اتصال واقعی و اجرای SELECT 1 امتیاز مستقل وجود دارد. ایجنت مدرس checker مورد اعتماد را در محیط خودش اجرا می‌کند؛ خطای زیرساخت با نقص پیاده‌سازی یکی نیست. هیچ رمز، API key، توکن یا URL واقعی اتصال در تحویل قرار ندهید.

در این POC، استفاده از آرایهٔ `real[]` با ۳۸۴ مؤلفه و محاسبهٔ دقیق شباهت کسینوسی مجاز است و استفاده از `pgvector` اختیاری است.

پاسخ‌ساز استخراجی و هویت/ارائه‌دهندهٔ آزمایشی باید صریح برچسب بخورند؛ اجرای زندهٔ OIDC یا LLM پولی الزامی نیست.

بخش ۱ معماری محصول و انتخاب مرحلهٔ توسعه | ۶٫۰ نمره

داده: سناریوهای مستقل بدون دیتاست

برای هر سناریو یک گزینه انتخاب و دلیل مبتنی بر قید مسئله بنویسید. موفقیت یک دمو را با آمادگی محصول برابر نگیرید.

۱٫۱ (۰٫۵ نمره) تیم فقط می‌خواهد بداند بازیابی روی ۲۴ سند از نظر فنی شدنی است؛ نه کاربر واقعی دارد و نه جریان پرداخت. کدام مرحله مناسب‌تر است؟

گزینه‌ها: الف) POC | ب) Product | ج) Prototype | د) MVP

۱٫۲ (۰٫۵ نمره) کاربران آزمایشی باید مسیر انتخاب پرونده و بازکردن استناد را تجربه کنند؛ پاسخ‌ها فعلاً از پیش نوشته شده‌اند. این خروجی چیست؟

گزینه‌ها: الف) Prototype | ب) Product | ج) POC | د) MVP

۱٫۳ (۰٫۵ نمره) یک گروه واقعی با ورود، دادهٔ پایدار و یک جریان کامل پاسخ مستند کار می‌کند و بازخورد استفاده می‌دهد. نزدیک‌ترین مرحله چیست؟

گزینه‌ها: الف) MVP | ب) Production کامل | ج) Notebook | د) Prototype

۱٫۴ (۰٫۵ نمره) کدام جزء باید مالکیت پرونده را قبل از هر واکشی بررسی کند؟

گزینه‌ها: الف) Backend و لایهٔ مجوز | ب) CSS | ج) متن پاسخ LLM | د) بردار embedding

۱٫۵ (۰٫۵ نمره) ماژول فقط متن را به بردار تبدیل می‌کند و ابزار، حافظه یا حلقهٔ عمل ندارد. مناسب‌ترین توصیف چیست؟

گزینه‌ها: الف) محصول | ب) Agent کامل | ج) مدل | د) درگاه هویت

۱٫۶ (۰٫۵ نمره) سامانه پس از دریافت پرسش، ابزار مناسب را انتخاب می‌کند، نتیجه را می‌سنجد و در صورت نیاز دوباره جستجو می‌کند. کدام لایه توصیف می‌شود؟

گزینه‌ها: الف) Agent یا orchestration | ب) ذخیرهٔ فایل | ج) فقط مدل | د) فقط CSS

۱٫۷ (۰٫۵ نمره) نمایش پیام «در حال بازیابی شواهد»، امکان لغو و بازکردن منبع بیشتر کدام هدف را دنبال می‌کند؟

گزینه‌ها: الف) جایگزینی احراز هویت | ب) افزایش ابعاد بردار | ج) بهبود UX و درک انتظار | د) آموزش مجدد مدل

۱٫۸ (۰٫۵ نمره) برای کاربران، جلسات و پیام‌ها، رابطه و تراکنش و Join لازم است. کدام ذخیره‌ساز پایه مناسب‌تر است؟

گزینه‌ها: الف) فقط cache | ب) فقط Vector DB | ج) RDBMS | د) فقط پوشهٔ تصویر

۱٫۹ (۰٫۵ نمره) پرسش «این درخواست چرا ۴ ثانیه طول کشید و کدام گام کند بود؟» با کدام شواهد بهتر پاسخ می‌گیرد؟

گزینه‌ها: الف) فقط رنگ رابط | ب) فقط نام مدل | ج) فقط میانگین روزانه | د) Trace با correlation ID و زمان هر گام

۱٫۱۰ (۰٫۵ نمره) محدودیت زمان و بودجه شدید است؛ تیم می‌خواهد پس از هر چرخه نسخهٔ قابل استفاده بدهد و بازخورد بگیرد. کدام رویکرد مناسب‌تر است؟

گزینه‌ها: الف) انتظار تا پایان همهٔ امکانات | ب) Agile با چرخه‌های کوتاه | ج) تغییر دائم بدون نسخه | د) حذف ارزیابی

۱٫۱۱ (۰٫۵ نمره) کدام معیار برای تصمیم میان دو ارائه‌دهندهٔ LLM معتبرتر است؟

گزینه‌ها: الف) فقط کشور سازنده | ب) فقط تعداد پارامتر | ج) فقط رتبهٔ عمومی | د) کیفیت و هزینه و تأخیر روی مجموعهٔ ارزیابی خود پروژه

۱٫۱۲ (۰٫۵ نمره) کدام تغییر برای گذار از دمو به محصول ضرورت بیشتری دارد؟

گزینه‌ها: الف) افزایش تزئینات | ب) حذف لاگ | ج) نام‌گذاری مدل به عنوان Agent | د) مالکیت داده و پایش و بازیابی پس از خطا

بخش ۲ قرارداد API و رفتار هنگام خطا | ۶٫۰ نمره

داده: سناریوهای مستقل بدون دیتاست

روش یا وضعیت مناسب را با توجه به معنای درخواست انتخاب کنید. موفقیت HTTP با موفقیت معنایی پاسخ یکسان نیست.

۲٫۱ (۰٫۵ نمره) واکنشی بدون تغییر داده برای گرفتن یک پروندهٔ مجاز طراحی می‌کنید. روش مناسب چیست؟

گزینه‌ها: الف) PATCH | ب) POST | ج) GET | د) DELETE

۲٫۲ (۰٫۵ نمره) درخواست ساخت جلسهٔ جدید با بدنهٔ JSON می‌فرستید. روش مناسب چیست؟

گزینه‌ها: الف) OPTIONS | ب) GET | ج) POST | د) HEAD

۲٫۳ (۰٫۵ نمره) توکن یا هویت معتبر ارائه نشده است. وضعیت اصلی چیست؟

گزینه‌ها: الف) 429 | ب) 403 | ج) 200 | د) 401

۲٫۴ (۰٫۵ نمره) کاربر شناسایی شده ولی مالک پرونده نیست. کدام وضعیت این تمایز را نشان می‌دهد؟

گزینه‌ها: الف) 403 | ب) 401 | ج) 503 | د) 201

۲٫۵ (۰٫۵ نمره) پارامتر top_k خارج از بازهٔ تعریف‌شدهٔ ۱ تا ۱۰ است و اعتبارسنجی طرح رد می‌شود. در قرارداد این تمرین کدام وضعیت است؟

گزینه‌ها: الف) 204 | ب) 422 | ج) 500 | د) 429

۲٫۶ (۰٫۵ نمره) ارائه‌دهنده 429 و Retry-After=2 برمی‌گرداند. رفتار مناسب چیست؟

گزینه‌ها: الف) تکرار بی‌نهایت فوری | ب) حذف احراز هویت | ج) تبدیل پاسخ به موفقیت | د) retry محدود با رعایت Retry-After و deadline

۲٫۷ (۰٫۵ نمره) درخواست POST ارسال شده ولی پاسخ قطع شده و معلوم نیست عملیات ثبت شده یا نه. کدام سازوکار خطر ثبت دوباره را کاهش می‌دهد؟

گزینه‌ها: الف) حذف شناسهٔ درخواست | ب) Idempotency-Key پایدار برای همان عملیات | ج) تغییر تصادفی بدنه | د) GET برای هر عملیات

۲٫۸ (۰٫۵ نمره) کلید idempotency قبلی با بدنهٔ متفاوت دوباره استفاده شده است. کدام پاسخ مناسب‌تر است؟

گزینه‌ها: الف) 409 با توضیح تعارض | ب) retry بیشتر | ج) موفقیت بی‌قید | د) 204 بدون توضیح

۲٫۹ (۰٫۵ نمره) فهرست اسناد رو به رشد است. کدام قرارداد از پاسخ‌های بسیار بزرگ جلوگیری می‌کند؟

گزینه‌ها: الف) فقط فشرده‌سازی تصویر | ب) ارسال همهٔ رکوردها همیشه | ج) حذف شناسه‌ها | د) pagination با حد بالا و ترتیب پایدار

۲٫۱۰ (۰٫۵ نمره) برای HTTP 401 ناشی از کلید اشتباه، چه سیاستی مناسب‌تر است؟

گزینه‌ها: الف) retry بی‌نهایت | ب) افزایش top_k | ج) توقف و گزارش خطای پیکربندی | د) نادیده‌گرفتن وضعیت

۲٫۱۱ (۰٫۵ نمره) کلید ارائه‌دهنده باید کجا نگهداری و مصرف شود؟

گزینه‌ها: الف) متن سند بازیابی‌شده | ب) JavaScript مرورگر | ج) پارامتر URL عمومی | د) Backend و secret محیطی

۲٫۱۲ (۰٫۵ نمره) در پاسخ 200، شناسهٔ استناد وجود خارجی ندارد. کدام نتیجه درست است؟

گزینه‌ها: الف) موفقیت کامل | ب) انتقال HTTP موفق ولی خروجی معنایی نامعتبر | ج) مدل embedding خراب است | د) خطای DNS

بخش ۳ هویت و حاکمیت داده | ۶٫۰ نمره

داده: سناریوهای مستقل بدون دیتاست

برای هر مورد، راه‌حل نرم‌افزاری قابل آزمون را انتخاب کنید؛ متن مدل نمی‌تواند مجوز تازه‌ای ایجاد کند.

۳٫۱ (۰٫۵ نمره) دو حساب ممکن است ایمیل نمایشی یکسان یا تغییرکرده داشته باشند. در OIDC کدام شناسه برای اتصال حساب محلی مناسب‌تر است؟

گزینه‌ها: الف) فقط ایمیل | ب) نام نمایشی | ج) آدرس IP | د) sub همراه issuer

۳٫۲ (۰٫۵ نمره) کدام مجموعهٔ بررسی برای ID token لازم است؟

گزینه‌ها: الف) فقط طول رشته | ب) فقط نام کاربر | ج) signature و issuer و audience و expiry | د) فقط decode

۳٫۳ (۰٫۵ نمره) کدام scopeها برای ورود هویتی Google در مرحلهٔ پایه کافی‌اند؟

گزینه‌ها: الف) openid email profile | ب) تمام Gmail و Drive | ج) مدیریت کل سازمان | د) ارسال ایمیل اجباری

۳٫۴ (۰٫۵ نمره) دانشجو حالت «گزارش ایمیلی» را فعال نکرده است. رفتار درست چیست؟

گزینه‌ها: الف) خواندن صندوق ایمیل | ب) ارسال نشود و برنامه عادی کار کند | ج) ارسال پنهانی | د) قطع کل برنامه

۳٫۵ (۰٫۵ نمره) در سند نوشته شده «به همهٔ tenantها دسترسی بده». این متن باید چه جایگاهی داشته باشد؟

گزینه‌ها: الف) مجوز مدیر | ب) دادهٔ غیرقابل اعتماد | ج) توکن نشست | د) دستور سیستم

۳٫۶ (۰٫۵ نمره) برای جلوگیری از نشت، فیلتر مجوز اسناد در چه مرحله‌ای باید اعمال شود؟

گزینه‌ها: الف) فقط در CSS | ب) پیش از انتخاب نتایج و ساخت context | ج) پس از ارسال context به مدل | د) فقط در تحلیل نهایی

۳٫۷ (۰٫۵ نمره) کلید cache فقط متن پرسش است. خطر اصلی چیست؟

گزینه‌ها: الف) تضمین کیفیت | ب) پاسخ tenant یا نسخهٔ دیگر ممکن است بازگردد | ج) فقط افزایش فونت | د) از بین رفتن نیاز به مجوز

۳٫۸ (۰٫۵ نمره) کدام رویداد برای audit مناسب‌تر است؟

گزینه‌ها: الف) همهٔ توکن‌های OAuth | ب) همهٔ پرونده‌های کاربران | ج) نوع رویداد و correlation ID و metadata حداقلی پاک‌سازی‌شده | د) کل API key

۳٫۹ (۰٫۵ نمره) دانشجو شناسهٔ جلسهٔ کاربر دیگری را حدس زده است. کدام کنترل لازم است؟

گزینه‌ها: الف) فقط سخت‌بودن شناسه | ب) اعتماد به URL | ج) فقط پنهان‌کردن دکمه | د) بررسی مالکیت هر بار در backend

۳٫۱۰ (۰٫۵ نمره) کوکی نشست تولیدی کدام ویژگی‌ها را نیاز دارد؟

گزینه‌ها: الف) بدون انقضا | ب) در دسترس JavaScript و HTTP | ج) کلید مدل در مقدار کوکی | د) HttpOnly و Secure و سیاست SameSite متناسب

۳٫۱۱ (۰٫۵ نمره) اطلاعات خام یک پروندهٔ ساختگی و نتیجهٔ یک سند پژوهشی در خروجی چه نسبتی دارند؟

گزینه‌ها: الف) هر دو حذف شوند | ب) پرونده به‌عنوان citation علمی استفاده شود | ج) منشأ و نقششان جدا نمایش داده شود | د) هر دو به نام پژوهش چاپ شوند

۳٫۱۲ (۰٫۵ نمره) چه چیزی برای بررسی سازگاری تغییر schema ضروری‌تر است؟

گزینه‌ها: الف) migration نسخه‌دار و آزمون بازیابی/rollback متناسب | ب) ویرایش دستی پایگاه بدون سابقه | ج) حذف کلید خارجی | د) فقط عوض‌کردن نام جدول

بخش ۴ استدلال دربارهٔ RAG و ارزیابی | ۶٫۰ نمره

داده: سناریوهای مستقل بدون دیتاست

پاسخ را بر اساس محدودیت‌های بازیابی و تولید انتخاب کنید و از تعبیر امتیاز شباهت به احتمال صحت پرهیز کنید.

۴٫۱ (۰٫۵ نمره) پاسخ به سیاست خصوصی شرکت نیاز دارد که در آموزش مدل نبوده است. کدام رویکرد پایه مناسب‌تر است؟

گزینه‌ها: الف) حدس مدل | ب) RAG با کنترل دسترسی | ج) فقط افزایش temperature | د) حذف سند

۴٫۲ (۰٫۵ نمره) سؤال موجودی زندهٔ انبار را می‌خواهد. کدام منبع مناسب‌تر است؟

گزینه‌ها: الف) فقط مقالهٔ قدیمی | ب) حافظهٔ مدل | ج) نام مدل بزرگ‌تر | د) ابزار یا API معتبر سامانهٔ موجودی

۴٫۳ (۰٫۵ نمره) تغییر اصلی مورد نیاز، قالب و لحن ثابت پاسخ است. کدام گزینه می‌تواند مناسب باشد؟

گزینه‌ها: الف) افزایش صرف top_k | ب) مهندسی prompt یا fine-tuning با ارزیابی | ج) حذف خروجی ساختاریافته | د) اعتماد به citation ساختگی

۴٫۴ (۰٫۵ نمره) بردارهای اسناد با مدل A و پرسش با مدل B ساخته شده‌اند ولی ابعاد برابرند. چه نتیجه‌ای درست است؟

گزینه‌ها: الف) همیشه سازگارند | ب) مجوز داده حذف می‌شود | ج) برابری بعد کافی نیست؛ فضای embedding و نسخه باید سازگار باشد | د) cosine حتماً صفر می‌شود

۴٫۵ (۰٫۵ نمره) مدل embedding حداکثر ۲۵۶ توکن می‌بیند ولی chunkها ۶۰۰ توکن‌اند. خطر اصلی چیست؟

گزینه‌ها: الف) بازیابی همهٔ متن تضمین است | ب) فقط افزایش سرعت SQL | ج) جایگزینی نیاز به OCR | د) truncation خاموش و حذف بخش مهم شاهد

۴٫۶ (۰٫۵ نمره) Recall@k را روی پرسش‌های بدون سند مرتبط چگونه باید مدیریت کرد؟

گزینه‌ها: الف) تقسیم بر صفر | ب) متریک پاسخ‌پذیرها و abstention خارج از پوشش را جدا گزارش کرد | ج) حذف اعلام‌نشدهٔ همهٔ خطاها | د) همه را خودکار یک حساب کرد

۴٫۷ (۰٫۵ نمره) چند chunk از یک سند در top-k هستند و gold در سطح سند است. چه تعریفی روشن‌تر است؟

گزینه‌ها: الف) chunk و سند را مخلوط کنیم | ب) هر chunk را سند مستقل بنامیم | ج) رتبه‌بندی یکتای اسناد و متریک سندی را صریح تعریف کنیم | د) فقط تعداد chunkها را گزارش کنیم

۴٫۸ (۰٫۵ نمره) روش lexical و dense مقیاس امتیاز متفاوت دارند. برای ترکیب پایه کدام روش مناسب‌تر است؟

گزینه‌ها: الف) Reciprocal Rank Fusion | ب) جمع خام بدون کالیبراسیون | ج) انتخاب با آزمون نهایی | د) حذف روش دوم

۴٫۹ (۰٫۵ نمره) آستانهٔ عدم پاسخ کجا باید انتخاب شود؟

گزینه‌ها: الف) با جواب درست آزمون در prompt | ب) پس از دیدن همهٔ خطاهای آزمون | ج) روی dev و سپس قفل شود | د) فقط روی آزمون نهایی

۴٫۱۰ (۰٫۵ نمره) شناسهٔ citation معتبر است و نقل‌قول در منبع وجود دارد. آیا ادعای نوشته‌شده لزوماً از آن نتیجه می‌شود؟

گزینه‌ها: الف) خیر؛ پشتیبانی معنایی ادعا بررسی جدا می‌خواهد | ب) امضای OAuth آن را اثبات می‌کند | ج) با top_k بیشتر قطعی است | د) بله همیشه

۴٫۱۱ (۰٫۵ نمره) در corpus دو سیاست با نسخه‌های قدیم و جدید تعارض دارند. چه رفتاری مناسب‌تر است؟

گزینه‌ها: الف) نمایش تعارض و اعمال سیاست نسخه/اعتبار و دسترسی | ب) همیشه اولین نتیجه | ج) ترکیب پنهانی هر دو | د) اختراع تاریخ

۴٫۱۲ (۰٫۵ نمره) نرخ عبور آزمون حمله برای مولد extractive برابر ۱۰۰٪ شده است. کدام نتیجه معتبر است؟

گزینه‌ها: الف) تمام ابزارها آزاد شوند | ب) فقط کنترل‌های همین مسیر و همین fixtureها آزموده شده‌اند | ج) هر LLM کاملاً امن است | د) نیازی به ارزیابی نیست

بخش ۵ کلاینت API و قرارداد خطا | ۸٫۰ نمره

داده: Day3_Datasets/04_API و API محلی آزمایشی

با FastAPI TestClient و httpx.MockTransport کار کنید. هویت X-User-ID و پاسخ‌های ارائه‌دهنده فقط fixture آموزشی‌اند؛ این بخش ادعای ورود واقعی Google یا فراخوانی LLM پولی ندارد.

۵٫۱ (۰٫۵ نمره) فایل request_logs.csv را ممیزی کنید؛ تعداد ردیف‌ها، یکتایی request_id و سهم خطاهای HTTP را گزارش دهید. مصنوعی‌بودن داده را در تفسیر نگه دارید.

۵٫۲ (۰٫۵ نمره) توزیع status را رسم و خطاها را به اعتبارسنجی/هویت، محدودیت نرخ و سرور تقسیم کنید. کدام گروه برای retry خودکار مناسب است؟

۵٫۳ (۰٫۵ نمره) طرح درخواست جستجو را با query سه تا هزار نویسه، top_k از ۱ تا ۱۰ و method محدود پیاده کنید؛ فیلد اضافه و ورودی نامعتبر را رد کنید.

۵٫۴ (۰٫۵ نمره) API پرونده‌ها را با صفحه‌بندی پایدار فراخوانی و تمام پرونده‌های U-002 را بدون تکرار جمع‌آوری کنید. حد بالای limit را در backend اعمال کنید.

۵٫۵ (۰٫۵ نمره) برای هویت غایب، مالکیت نادرست، شناسهٔ ناموجود و صفحه‌بندی نامعتبر درخواست بسازید و وضعیت HTTP مناسب را اثبات کنید.

۵٫۶ (۰٫۵ نمره) شش سناریوی retry_scenarios.jsonl را با حداکثر سه تلاش اجرا کنید. Retry-After و backoff را بدون خواب واقعی ثبت و تفاوت 401 و 503 را تحلیل کنید.

۵٫۷ (۰٫۵ نمره) برای ساخت جلسه از Idempotency-Key استفاده کنید. دو درخواست یکسان باید یک session_id بدهند؛ کلید یکسان با case_id متفاوت باید تعارض بدهد.

۵٫۸ (۰٫۵ نمره) در خطای مداوم سرور، سقف تلاش را آزمون کنید و جمع backoff را محاسبه کنید. توضیح دهید چرا سقف تلاش به‌تنهایی deadline کل درخواست را تضمین نمی‌کند.

۵٫۹ (۱ نمره) یک ReadTimeout شبیه‌سازی و خطای قابل فهم برگردانید؛ تفاوت timeout اتصال/خواندن و بودجهٔ کل را توضیح دهید و هیچ خطایی را موفقیت معرفی نکنید.

۵٫۱۰ (۱ نمره) با نرخ‌های فرضی provider_config.json هزینهٔ ورودی/خروجی هر درخواست و جمع هر provider را محاسبه و مقایسه کنید. واحد و فرض قیمت را صریح بنویسید.

۵٫۱۱ (۱ نمره) یک رابط provider بسازید که با تعویض base_url و model_id به دو endpoint سازگار متصل شود. قرارداد درخواست را با MockTransport آزمون کنید و تست را از فراخوانی واقعی LLM جدا گزارش دهید.

۵٫۱۲ (۱ نمره) پاسخ خطا را به envelope ثابت شامل message، code و correlation_id تبدیل کنید و یک 401 و یک 422 را در API آزمایشی بررسی کنید.

بخش ۶ اتصال واقعی دیتابیس و قیود داده | ۸٫۰ نمره

داده: Day3_Datasets/03_Application و PostgreSQL آزمایشی

با Docker یا DATABASE_URL به PostgreSQL واقعی وصل شوید. از schema اختصاصی DB_SCHEMA استفاده کنید؛ مسیر مرجع day3_reference است. قرارداد حداقل جدول‌ها: users(user_id,role,tenant)، cases(case_id,owner_id,topic,summary)، documents(doc_id,version,content_hash)، chunks(chunk_id,doc_id,content,embedding,model_id,model_revision). embedding می‌تواند []real با بعد کنترل‌شدهٔ ۳۸۴ یا نوع vector(384) باشد. secrets در خروجی تحویل قرار نگیرند. checker مستقل در Day3_Grading ارائه شده است.

۶٫۱ (۰٫۵ نمره) اتصال واقعی PostgreSQL را از DATABASE_URL برقرار کنید، SELECT 1 و نسخهٔ سرور را بخوانید و timeout اتصال را محدود کنید. در نبود سرویس، وضعیت infrastructure_error بدهید؛ موفقیت ساختگی گزارش نکنید.

۶٫۲ (۰٫۵ نمره) در schema اختصاصی، جدول‌های قراردادی و جلسات/پیام‌ها را با کلید اصلی و خارجی بسازید؛ ۲۰ کاربر و ۱۲۰ پرونده را idempotent seed کنید. اسکریپت migration/seed را همراه پاسخ تحویل دهید.

۶٫۳ (۰٫۵ نمره) یک پرونده با owner ناموجود وارد کنید و ثابت کنید کلید خارجی آن را رد می‌کند. پس از خطا، اتصال باید برای کوئری بعدی قابل استفاده باشد.

۶٫۴ (۰٫۵ نمره) در یک تراکنش ابتدا جلسه بسازید و سپس پیام با session_id نامعتبر درج کنید. خطا باید کل تراکنش را rollback کند؛ تعداد جلسات قبل و بعد را مقایسه کنید.

۶٫۵ (۰٫۵ نمره) پرس‌وجوی پارامتری برای user_id بسازید و ورودی شبیه SQL injection را آزمون کنید. ورودی باید مقدار تلقی شود و تعداد کاربران را تغییر ندهد.

۶٫۶ (۰٫۵ نمره) منطق مالکیت را روی PostgreSQL آزمون کنید: مالک پرونده و admin مجاز، دانشجوی دیگر غیرمجاز. برای API نهایی یک adapter بسازید تا همین دیتابیس واقعی مصرف شود.

۶٫۷ (۰٫۵ نمره) ایندکس owner_id را بررسی و EXPLAIN پرس‌وجوی فهرست پروندهٔ یک مالک را گزارش کنید. اگر planner برای جدول کوچک sequential scan انتخاب کرد، دلیل قابل دفاع بیاورید.

۶٫۸ (۰٫۵ نمره) metadata همهٔ اسناد را دو بار UPSERT و ثابت کنید تعداد افزایش نمی‌یابد. یک migration جایگزین برای vector(384) و ثبت نام/نسخهٔ embedding ارائه کنید؛ اجرای pgvector را جدا از اتصال پایه گزارش دهید.

۶٫۹ (۱ نمره) با توکن‌های امضاشدهٔ آزمایشی، audience، issuer، signature و expiry را با کتابخانه معتبر آزمون کنید؛ یک issuer نامعتبر و یک توکن منقضی باید رد شوند. تفاوت fixture با Google OIDC واقعی را بنویسید.

۶٫۱۰ (۱ نمره) قرارداد حداقل scope ورود، ویژگی‌های کوکی و رضایت جدا برای گزارش ایمیلی را به‌شکل تنظیمات قابل بررسی بنویسید. هیچ client secret واقعی در artifact قرار ندهید.

۶٫۱۱ (۱ نمره) پاک‌سازی بازگشتی metadata را روی رویدادهای دارای api_key و ساختار تودرتو اجرا کنید. در خروجی نهایی هیچ TEST-ONLY-SECRET باقی نماند.

۶٫۱۲ (۱ نمره) checker مستقل مدرس را در حالت connection-only اجرا و connection_check.json را ذخیره کنید. سه وضعیت passed، failed و infrastructure_error و کد خروجشان را برای تصحیح ایجنتیک تعریف کنید.

بخش ۷ ورود اسناد و حفظ منشأ | ۱۰٫۰ نمره

داده: Day3_Datasets/01_Corpus و Application/policies.jsonl_03

۲۴ PEP واقعی با نسخهٔ ثابت و دو PDF آزمایشی در دسترس‌اند. متن خام و شناسهٔ سند/نسخه و بازهٔ کاراکتری شاهد را حفظ کنید. PDF تصویری عمداً متن استخراج‌پذیر ندارد و نباید بی‌صدا ایندکس شود.

۷٫۱ (۰٫۵ نمره) manifest را با فایل‌های خام تطبیق دهید و SHA-256 همهٔ اسناد را بررسی کنید؛ تعداد اسناد و نسخهٔ corpus را ثبت کنید.

۷٫۲ (۰٫۵ نمره) هر دو PDF fixture را صفحه‌به‌صفحه بخوانید؛ تعداد صفحه و نویسهٔ استخراج‌شده را گزارش و سند تصویری را برای OCR/بازبینی علامت بزنید.

۷٫۳ (۰٫۵ نمره) عنوان، شناسه، نسخه و بخش‌های RST را استخراج کنید و یک نمونه را به مسیر و URL اصلی وصل کنید؛ metadata اختراعی ایجاد نکنید.

۷٫۴ (۰٫۵ نمره) با tokenizer همان chunk، embeddingهای حداکثر ۲۲۰ توکن و هم‌پوشانی ۴۰ توکن بسازید؛ متن هر chunk باید substring واقعی منبع باشد. توزیع طول را نمایش دهید.

۷٫۵ (۱ نمره) برای همهٔ chunkها با start/end متن اصلی را بازسازی و تطابق hash را آزمون کنید؛ یک مسیر استناد از chunk تا سند و بخش را نمایش دهید.

۷٫۶ (۱ نمره) chunking را با همان تنظیمات دوباره اجرا و پایداری chunk_id را آزمون کنید. شناسه باید به سند، نسخه، بازه و محتوا وابسته باشد.

۷٫۷ (۱ نمره) یک سند را در نسخهٔ آزمایشی تغییر دهید و ثابت کنید شناسهٔ chunkهای نسخهٔ قبلی با نسخهٔ جدید مخلوط نمی‌شود. فایل اصلی را تغییر ندهید.

۷٫۸ (۱ نمره) سه chunk را عمداً تکرار و با کلید مناسب رفع تکرار کنید. تفاوت تکرار دقیق و سند مشابهِ دارای نسخه یا مجوز متفاوت را توضیح دهید.

۷٫۹ (۱ نمره) اندازه‌های ۱۱۰، ۲۲۰ و ۴۴۰ توکن را از نظر تعداد chunk و خطر عبور از سقف embedding مقایسه کنید؛ برای chunkهای بلند truncation را پنهان نکنید.

۷٫۱۰ (۱ نمره) چهار سیاست مصنوعی را با access و tenant وارد کنید و metadata لازم برای فیلتر پیش از top-k را نشان دهید؛ متن قدیمی را به‌عنوان archived نگه دارید.

۷٫۱۱ (۱ نمره) metadata و متن chunkها را در SQLite محلیِ تست ذخیره و درج دوباره را بدون رکورد تکراری اجرا کنید. این مسیر را از PostgreSQL اصلی تفکیک کنید.

۷٫۱۲ (۱ نمره) artifact قابل بازتولید شامل chunks.jsonl و fingerprint تنظیمات و corpus بسازید. برای فایل تولیدشده hash و تعداد رکورد را ثبت کنید.

بخش ۸ بردارسازی و بازیابی چندمسیره | ۱۲ نمره

داده: Corpus_01 و Application/policies.jsonl_03 و مدل محلی Day3_Resources

از مدل عصبی واقعیِ همراه بسته استفاده کنید. این مدل انگلیسی است؛ پرسش‌ها و corpus عمداً انگلیسی‌اند. pgvector اختیاری است؛ مسیر اجباری شامل ذخیرهٔ []real در PostgreSQL و بازیابی دقیق cosine در حافظه است. زمان‌های اجرا وابسته به دستگاه‌اند.

۸٫۱ (۱ نمره) نسخه، مجوز، بعد خروجی و سقف توکن مدل همراه را ثبت کنید و hash تمام فایل‌های آن را بسنجید. تفاوت سقف tokenizer و طول chunk را توضیح دهید.

۸٫۲ (۱ نمره) تمام chunkهای ۲۲۰ توکنی را batch encode و L2-normalize کنید؛ زمان، شکل ماتریس، کمترین و بیشترین norm و تعداد مقدار نامتناهی را گزارش دهید.

۸٫۳ (۱ نمره) cosine دو بردار را هم با فرمول صریح و هم dot product نرمال‌شده محاسبه کنید. تفاوت similarity و cosine distance و جهت مرتب‌سازی را بنویسید.

۸٫۴ (۱ نمره) baseline بازیابی TF-IDF با unigram/bigram بسازید و top-3 سند متمایزِ پرسش indentation را همراه score نشان دهید.

۸٫۵ (۱ نمره) همان پرسش را با dense cosine بازیابی و top-3 سند را با baseline مقایسه کنید؛ scoreهای دو روش را هم‌مقیاس فرض نکنید.

۸٫۶ (۱ نمره) دو رتبه‌بندی را با RRF و ثابت ۶۰ ترکیب کنید و top-3 سند متمایز را بسازید. مزیت ترکیب رتبه نسبت به جمع مستقیم score را توضیح دهید.

۸٫۷ (۱ نمره) بردارهای واقعی را با متن و نام/نسخهٔ مدل در PostgreSQL UPSERT کنید؛ اجرای دوباره نباید شمار رکورد را زیاد کند. شمار و بعدِ بردار بازخوانی‌شده را ثبت کنید.

۸٫۸ (۱ نمره) یک chunk را از PostgreSQL بخوانید و با بردار اصلی مقایسه کنید؛ جستجوی دقیق روی بردارهای بازخوانی‌شده باید top-1 محلی را بازتولید کند.

۸٫۹ (۱ نمره) با افزودن سیاست‌ها یک ایندکس آزمایشی بسازید و ACL را قبل از top-k اعمال کنید. برای کاربر tenant T-0، هیچ سیاست داخلی T-1 نباید برگردد؛ admin را جدا بسنجید.

۸٫۱۰ (۱ نمره) برای top-10 یک پرسش، context حداکثر ۷۰۰ توکنی بسازید و تعداد شواهد انتخاب/حذف‌شده را گزارش کنید. اثر ترتیب شواهد و هزینهٔ prompt را تحلیل کنید.

۸٫۱۱ (۱ نمره) پس از warm-up، تأخیر بازیابی lexical/dense/hybrid را روی ۱۲ پرسش train با embedding cache گرم بسنجید و p50/p95 گزارش کنید. زمان cold embedding را جدا نگه دارید.

۸٫۱۲ (۱ نمره) metadata مدل را عمداً ناسازگار کنید و بارگذاری را پیش از query رد کنید. fingerprint معتبر ایندکس را با model revision و بعد و chunk config ذخیره کنید.

بخش ۹ ارزیابی بازیابی و کنترل نشت آزمون | ۱۰٫۰ نمره

داده: Evaluation_02 و Day3_Reference/qrels_all.jsonl فقط برای پاسخ مدرس

تنظیمات فقط با train/dev انتخاب شوند. برای test دانشجو فقط پرسش‌ها را می‌بیند؛ مرجع مدرس gold آن را دارد. relevance در سطح سند است؛ Recall/MRR/nDCG را در همین سطح بسنجید. پاسخ‌ناپذیرها از میانگین معیار بازیابی حذف و جدا ارزیابی شوند.

۹٫۱ (۰٫۵ نمره) تعداد پرسش‌های train/dev/test و توزیع پاسخ‌پذیر/ناپذیر فقط در train/dev را بررسی کنید؛ برچسب test پنهان است. تکرار دقیق متن را بسنجید و محدودیت هم‌خانوادگی معنایی پرسش‌ها را توضیح دهید.

۹٫۲ (۰٫۵ نمره) MRR@3، Recall@3 و nDCG@3 را روی دو مثال دستی آزمون کنید: gold={A} با رتبه‌های [B,A,C] و [B,C,D]. انتظار دقیق هر سه معیار را بنویسید.

۹٫۳ (۰٫۵ نمره) روی ۲۴ پرسش پاسخ‌پذیر dev، سه روش lexical/dense/hybrid را در k=3 مقایسه و هر سه معیار را جدول و نمودار کنید؛ سند تکراری را در رتبه‌بندی معیار نشمارید.

۹٫۴ (۰٫۵ نمره) روش منتخب را فقط با MRR@3 روی dev و قاعدهٔ رفع تساوی lexical سپس dense سپس hybrid انتخاب و قبل از بازکردن gold test قفل کنید.

۹٫۵ (۱ نمره) برای روش منتخب، حساسیت k در ۱، ۳ و ۵ را روی dev نشان دهید. علت غیرکاهشی بودن Recall@k و امکان تغییر MRR را توضیح دهید.

۹٫۶ (۱ نمره) سه خطای اول dev را با query_id، سند gold و سند اول بررسی کنید؛ اگر کمتر از سه خطا بود همان تعداد را گزارش کنید. خطای سند و خطای passage را از هم تفکیک کنید.

۹٫۷ (۱ نمره) پس از قفل تنظیمات، فایل prediction برای همهٔ پرسش‌های test تولید کنید. مدرس با gold جدا test را یک‌بار می‌سنجد؛ دانشجو نباید برای این بخش gold test دریافت کند.

۹٫۸ (۱ نمره) برای Recall@3 روش منتخب روی dev، فاصلهٔ bootstrap صدک ۹۵٪ با ۲۰۰۰ بازنمونه و seed ثابت بسازید. محدودیت وابستگی پارافرایزها و حجم کوچک را توضیح دهید.

۹٫۹ (۱ نمره) برای تشخیص بی‌شاهد بودن، آستانهٔ بیشترین dense cosine را فقط روی dev انتخاب کنید؛ balanced accuracy پاسخ‌پذیر/ناپذیر را بیشینه و در تساوی آستانهٔ بزرگ‌تر را بگیرید.

۹٫۱۰ (۱ نمره) آستانهٔ ثابت را روی پرسش‌های عمومی test اجرا کنید؛ query_id، score و accepted را در answerability_predictions.jsonl تحویل دهید و تعداد پذیرش/عدم پاسخ را گزارش کنید. مدرس با gold پنهان false accept و false reject را می‌سنجد؛ آستانه را با test تغییر ندهید.

۹٫۱۱ (۱ نمره) روی شش پرسش dense retrieval، dev با chunkهای ۱۱۰ و ۲۲۰ توکنی را مقایسه کنید. این ablation را از نتیجهٔ قفل‌شدهٔ test جدا و هزینهٔ تعداد بردارها را گزارش کنید.

۹٫۱۲ (۱ نمره) گزارش ارزیابی قابل خواندن ماشین با split، واحد معیار، محدودیت‌ها، config hash و نتایج ذخیره کنید. سه ادعایی که این benchmark پشتیبانی نمی‌کند بنویسید.

بخش ۱۰ انتخاب مدل و ساخت مسیریاب عصبی | ۱۰٫۰ نمره

داده: Day3_Datasets/05_Router/requests.csv

دادهٔ این بخش مصنوعی است و چهار مسیر both، research، history و unsupported دارد. جداسازی بر اساس template_group انجام شده؛ split آماده را حفظ کنید. test برای تنظیم مدل یا تصمیم آستانه مصرف نشود.

۱۰٫۱ (۰٫۵ نمره) توزیع کلاس‌ها و splitها را بررسی و ثابت کنید template_group مشترک بین train/dev/test وجود ندارد. خطر split تصادفی روی این داده را تحلیل کنید.

۱۰٫۲ (۰٫۵ نمره) baseline قانون‌محور برای چهار مسیر بسازید و accuracy و macro-F1 آن را روی dev ثبت کنید. قوانین را فقط با نمونه‌های train طراحی کنید.

۱۰٫۳ (۰٫۵ نمره) Pipeline شامل TF-IDF unigram/bigram و LogisticRegression بسازید؛ C را از ۰٫۱، ۱ و ۱۰ فقط با macro-F1 dev انتخاب کنید. fit واژگان فقط روی train باشد.

۱۰٫۴ (۰٫۵ نمره) embedding ثابت مدل محلی را به‌عنوان feature برای مسیریاب بسازید. شکل norm، train/dev/test و تفاوت feature extraction با fine-tuning را توضیح دهید.

۱۰٫۵ (۱ نمره) شبکهٔ PyTorch با ورودی ۳۸۴، یک لایهٔ مخفی ۶۴، ReLU، Dropout=0.1 و خروجی چهارکلاسه بسازید. تعداد پارامتر قابل آموزش و سازگاری shape را محاسبه کنید.

۱۰٫۶ (۱ نمره) شبکه را با AdamW، lr=0.003، batch=32 و حداکثر ۶۰ epoch آموزش دهید؛ بهترین checkpoint را با macro-F1 dev و patience=10 انتخاب و منحنی loss و F1 را رسم کنید.

۱۰٫۷ (۱ نمره) پس از قفل C و checkpoint، سه baseline را یک‌بار روی test مقایسه کنید. accuracy و macro-F1 و confusion matrix شبکه را بدهید و مدل مناسب استقرار آزمایشی را با دلیل انتخاب کنید.

۱۰٫۸ (۱ نمره) softmax و confidence شبکه را روی dev محاسبه کنید؛ نرخ پوشش و دقت درخواست‌های پذیرفته‌شده در آستانه‌های ۰٫۵، ۰٫۷ و ۰٫۹ را گزارش دهید. confidence را معادل احتمال کالیبره فرض نکنید.

۱۰٫۹ (۱ نمره) یک fallback با آستانهٔ ثابت ۰٫۷ طراحی کنید که در confidence پایین به clarify برود. روی یک batch dev نشان دهید چند درخواست نیازمند روشن‌سازی می‌شوند؛ unsupported را با confidence پایین یکی نگیرید.

۱۰٫۱۰ (۱ نمره) سه خطای test شبکه را با query و حقیقت و پیش‌بینی نمایش دهید؛ اگر خطا صفر بود از دو مورد با confidence کمتر استفاده و این تغییر را صریح اعلام کنید.

۱۰٫۱۱ (۱ نمره) تأثیر حذف موضوع را روی dev بررسی کنید: نام ۱۰ موضوع را با TOPIC جایگزین و macro-F1 مدل خطی ثابت را دوباره محاسبه کنید. شبکه یا مدل را با dev بازآموزی نکنید.

۱۰٫۱۲ (۱ نمره) model card شامل منشأ مصنوعی، split گروهی، معیارها، نسخه encoder، دامنهٔ زبان و موارد استفادهٔ نامناسب بسازید و وزن‌ها و ترتیب کلاس‌ها را ذخیره کنید.

بخش ۱۱ گردش کار LangGraph و پاسخ مستند | ۱۰٫۰ نمره

داده: Corpus_01 و Application_03 و Robustness_06

یک StateGraph واقعی بسازید. تولید پاسخ در مرجع یک baseline استخراجی قطعی است؛ هیچ ادعای اجرای LLM پولی یا ورود Google زنده نداریم. دادهٔ سند و تاریخچه ابزار است و نباید به دستور قابل اعتماد تبدیل شود.

۱۱٫۱ (۰٫۵ نمره) قرارداد state شامل answer، history، evidence، route، case، user، query و trace را تعریف کنید؛ state اولیه باید secret نداشته باشد و per-request باشد.

۱۱٫۲ (۰٫۵ نمره) node ورود را بنویسید که پیش از هر ابزار مالکیت را در PostgreSQL بسنجد. برای کاربر غیرمالک مسیر deny و بدون واکشی evidence/history بسازید.

۱۱٫۳ (۰٫۵ نمره) node مسیریابی با fallback بسازید و history/research/both را به ابزارهای محدود نگاشت کنید. clarify و unsupported باید بدون جستجوی خصوصی پاسخ کنترل‌شده بدهند.

۱۱٫۴ (۰٫۵ نمره) ابزار تاریخچه را با query پارامتری و owner check بسازید و مسیر research را به شواهد public یا tenant مجاز محدود کنید. تاریخچه را به‌عنوان منبع پژوهشی عمومی cite نکنید.

۱۱٫۵ (۱ نمره) پاسخ ساختاریافته با schema اعتبارسنجی و citation IDهای واقعی تولید کنید؛ سه حالت general/rag/both را تعریف کنید. مرجع استخراجی در general باید ناتوانی تولید آزاد را صریح نشان دهد.

۱۱٫۶ (۱ نمره) validator استناد را روی چهار candidate همراه بسنجید: معتبر، ID جعلی، بدون استناد و quote ناموجود. تعداد قبول/رد و علت رد هر مورد را بدهید.

۱۱٫۷ (۱ نمره) یک claim عمداً ناسازگار با quote واقعی بسازید و نشان دهید validator ساختاری ممکن است آن را قبول کند. برای baseline استخراجی شرط برابری claim و quote اضافه و آن را رد کنید.

۱۱٫۸ (۱ نمره) node اعتبارسنجی و گراف واقعی را با شاخه‌های مجوز، route، ابزار، تولید و validate بسازید؛ سپس یک درخواست مجاز را invoke و trace آن را ثبت کنید.

۱۱٫۹ (۱ نمره) درخواست غیرمالک را از کل گراف عبور دهید؛ هیچ history یا research نباید در trace آن باشد. بلافاصله درخواست مالک را اجرا و جداسازی state را بررسی کنید.

۱۱٫۱۰ (۱ نمره) ۳۰ حملهٔ مصنوعی را به‌عنوان متن غیرقابل اعتماد بسته‌بندی کنید؛ هیچ ابزار یا secret به لایهٔ استخراجی ندهید و سلامت مرز داده/دستور را بسنجید. نتیجه را نرخ مقاومت LLM زنده معرفی نکنید.

۱۱٫۱۱ (۱ نمره) cache key را با tenant، user، مدل، corpus و prompt version بسازید؛ تغییر هرکدام باید miss بدهد. اختلاف query مشابه با مجوز متفاوت را با تست نشان دهید.

۱۱٫۱۲ (۱ نمره) برای هر گام یک رویداد کمینه با correlation ID مشترک و metadata پاک‌سازی‌شده تولید کنید. trace پاسخ را ذخیره کنید و از ذخیرهٔ متن خصوصی کامل در لاگ پیش‌فرض پرهیز کنید.

بخش ۱۲ یکپارچه‌سازی و آمادگی تحویل | ۸٫۰ نمره

داده: همهٔ داده‌ها و Day3_Grading و PostgreSQL واقعی

API نهایی را با PostgreSQL بخش ۶ و گراف بخش ۱۱ یکپارچه کنید. ابزار TestClient، درخواست HTTP را در فرایند اجرا می‌کند؛ استقرار اینترنتی جزو اجرای مرجع نیست. هویت X-User-ID فقط fixture کلاس است و برای محصول، نشست معتبر OIDC جایگزین آن می‌شود.

۱۲٫۱ (۰٫۵ نمره) API پرونده/جلسه را به PostgreSQLAdapter متصل و health، پروندهٔ مالک و پروندهٔ غیرمالک را از TestClient بخوانید. موتور دیتابیسِ این آزمون را صریح گزارش کنید.

۱۲٫۲ (۰٫۵ نمره) endpoint پاسخ با schema ورودی، کنترل هویت/مالکیت و invoke گراف اضافه کنید. پاسخ باید trace ID و claims ساختاریافته داشته باشد و خطای مجوز، وضعیت 403 بدهد.

۱۲٫۳ (۰٫۵ نمره) چهار مسیر منفی endpoint را آزمون کنید: بدون هویت، غیرمالک، query کوتاه و فیلد اضافه. وضعیت‌ها به‌ترتیب باید 401،403،422،422 باشند و متن پرونده در خطا نباشد.

۱۲٫۴ (۰٫۵ نمره) روی API متصل به PostgreSQL یک POST ساخت جلسه را دوبار با کلید یکسان اجرا کنید؛ شناسه یکسان و فقط یک رکورد جدید انتظار می‌رود. برخورد همان کلید با پروندهٔ دیگر باید 409 شود.

۱۲٫۵ (۰٫۵ نمره) یک نمای HTML حداقلی RTL برای نمایش پاسخ و منبع بسازید. خروجی شامل متن مشکوک <script> باید escape شود و در JavaScript برای متن پاسخ از textContent استفاده شود.

۱۲٫۶ (۰٫۵ نمره) از ۴۸۰۰ رویداد، traceهای کامل و نرخ خطای هر گام را بسازید؛ p50/p95 مجموع latency گام‌ها در هر trace را با نمودار گزارش کنید و محدودیت تفسیر latency مصنوعی را بنویسید.

۱۲٫۷ (۰٫۵ نمره) یک regression gate با کنترل مالکیت، idempotency، نسخهٔ embedding، استناد و پاک‌سازی لاگ تعریف کنید؛ نتایج واقعی قبلی را جمع و در regression_gate.json ذخیره کنید.

۱۲٫۸ (۰٫۵ نمره) قرارداد CI/CD و health را به فایل قابل بررسی تبدیل کنید: نصب وابستگی، آماده‌سازی سرویس، migration، آزمون، توقف هنگام شکست و rollback. رازها باید از env خوانده شوند.

۱۲٫۹ (۱ نمره) checker مستقل را این‌بار در حالت کامل روی PostgreSQL اجرا کنید؛ FK، seed، schema، SELECT 1، بردار ۳۸۴بعدی و rollback باید واقعاً سنجیده شوند. database_check.json و exit code تحویل دهید.

۱۲٫۱۰ (۱ نمره) برای دو محیط Docker و DATABASE_URL یک دستورالعمل بازتولید بنویسید و manifest تحویل با hash فایل‌های کلیدی بسازید. رشتهٔ اتصال واقعی نباید در JSON، notebook یا HTML خروجی قرار گیرد.

۱۲٫۱۱ (۱ نمره) rubric اجرایی برای تصحیح ایجنتیک بنویسید: قرارداد schema و seed، آزمون مستقل، تمایز خطای زیرساخت، و بازبینی تحلیل‌ها. برای سه نوع خطا تصمیم متفاوت تعریف کنید.

۱۲٫۱۲ (۱ نمره) گزارش نهایی با سه دسته بسازید: واقعاً اجراشده، fixture، و اجرانشده. پنج اقدام اولویت‌دار برای تبدیل POC به محصول و خطرِ ادعای بیش از شواهد را تحلیل کنید.

معیار تصحیح هر زیرسؤال عملی: ۶۰٪ پیاده‌سازی و خروجی قابل بازتولید، ۴۰٪ تحلیل مستند و بیان محدودیت‌ها. سؤال مفهومی: ۶۰٪ گزینه و ۴۰٪ دلیل. اعداد وابسته به دستگاه مثل زمان اجرا با عدد مرجع تطبیق سخت‌گیرانه ندارند.

منشأ، مجوز، فرهنگ داده و راهنمای اجرا در READMEهای همراه آمده است. دادهٔ مصنوعی را واقعیت بیرونی و fixture را سرویس زنده معرفی نکنید.